OUTLINE SKRIPSI NON KELAS/ARTIKEL ILMIAH

Analisis Performa Horizontal Pod Autoscaler (HPA) terhadap Stabilitas dan Efisiensi Resource pada Aplikasi Cloud-Native Berbasis Kubernetes

Performance Analysis of Horizontal Pod Autoscaler (HPA) on Stability and Resource Efficiency in Cloud-Native Applications Based on Kubernetes

Topik: Networking

2702231464 / Ignatius Kevin Wijaya / Computer Science / 082123929119

Computer Science

Computer Science Study Program

School of Computer Science

Universitas Bina Nusantara

Jakarta

2026/2027

DAFTAR ISI

Daftar Isi i
1. Latar Belakang 1
2. Rumusan Masalah 1
3. Ruang Lingkup 1
4. Tujuan dan Manfaat
    4.1. Tujuan 1
    4.2. Manfaat 1
5. Metodologi Penelitian 1
Daftar Pustaka 2

1. LATAR BELAKANG

Perkembangan arsitektur cloud-native dan microservices mendorong kebutuhan sistem yang mampu melakukan penskalaan otomatis untuk menjaga performa dan ketersediaan layanan. Kubernetes sebagai platform orkestrasi container menyediakan mekanisme Horizontal Pod Autoscaler (HPA) yang memungkinkan sistem menyesuaikan jumlah pod berdasarkan metrik tertentu, seperti penggunaan CPU.

Meskipun HPA dirancang untuk meningkatkan stabilitas dan efisiensi resource, implementasi dan konfigurasi yang kurang tepat dapat menyebabkan overprovisioning, fluktuasi pod yang tidak stabil (thrashing), atau penurunan kualitas layanan. Oleh karena itu, diperlukan analisis empiris untuk mengevaluasi bagaimana HPA mempengaruhi stabilitas sistem dan efisiensi penggunaan resource pada aplikasi cloud-native berbasis Kubernetes, khususnya dalam skenario beban dinamis.

Penelitian ini berfokus pada evaluasi performa sistem dengan membandingkan kondisi tanpa HPA dan dengan HPA aktif, guna mengetahui dampaknya terhadap latency, throughput, utilisasi CPU, serta waktu respons penskalaan (scaling time).

2. RUMUSAN MASALAH

Rumusan masalah dalam penelitian ini meliputi:

- Bagaimana pengaruh penerapan Horizontal Pod Autoscaler (HPA) terhadap latency dan throughput aplikasi cloud-native berbasis Kubernetes?
- Bagaimana pengaruh HPA terhadap stabilitas sistem yang diukur melalui variasi latency, tingkat error, dan konsistensi jumlah pod saat terjadi perubahan beban?
- Sejauh mana konfigurasi ambang batas CPU pada HPA memengaruhi efisiensi penggunaan resource yang diukur melalui rata-rata CPU utilization dan jumlah pod aktif?
- Apakah terdapat trade-off antara stabilitas layanan dan efisiensi resource dalam penerapan HPA?

3. RUANG LINGKUP

Ruang lingkup penelitian ini dibatasi sebagai berikut:

1. Penelitian berfokus pada analisis mekanisme Horizontal Pod Autoscaler (HPA) berbasis metrik CPU pada lingkungan Kubernetes untuk mengevaluasi dampaknya terhadap stabilitas sistem, efisiensi resource, dan perilaku penskalaan aplikasi.
2. Penelitian tidak mencakup mekanisme autoscaling lainnya seperti Vertical Pod Autoscaler (VPA) maupun Cluster Autoscaler, sehingga analisis difokuskan pada perbandingan kondisi baseline (tanpa autoscaling) dan dengan HPA.
3. Lingkungan pengujian menggunakan satu cluster Kubernetes skala kecil yang dikonfigurasi khusus untuk keperluan eksperimen dan pengambilan data secara terkontrol.
4. Aplikasi uji berupa aplikasi e-commerce sederhana berbasis arsitektur microservices ringan yang dikontainerisasi, terdiri dari beberapa layanan utama (misalnya layanan produk, pemesanan, dan pengguna). Arsitektur dirancang sederhana untuk menjaga konsistensi eksperimen dan meminimalkan variabel eksternal yang dapat memengaruhi hasil pengujian.
5. Parameter evaluasi yang dianalisis meliputi metrik yang merepresentasikan stabilitas sistem, efisiensi resource, dan perilaku scaling, yaitu:
   - p95 latency
   - Error rate (%)
   - Degradasi latency saat terjadi lonjakan beban
   - Throughput
   - Average CPU utilization (%)
   - Persentase idle resource
   - Pod utilization ratio
   - Jumlah pod aktif saat beban puncak
   - Waktu penskalaan (scaling time)
   - Waktu pemulihan setelah lonjakan beban
6. Pengujian dilakukan menggunakan dua skenario beban kerja, yaitu:
   - Peningkatan beban secara bertahap (gradual load increase)
   - Lonjakan trafik mendadak (traffic spike)
7. Penelitian tidak membahas aspek jaringan tingkat lanjut, optimasi penyimpanan, multi-cluster architecture, keamanan lanjutan, maupun konfigurasi spesifik penyedia

layanan cloud tertentu, karena fokus penelitian berada pada evaluasi performa HPA pada level aplikasi dan resource komputasi.

4. TUJUAN DAN MANFAAT

4.1. Tujuan

Penelitian ini bertujuan untuk:

1. Menganalisis dampak penggunaan HPA terhadap stabilitas aplikasi berbasis Kubernetes.
2. Mengukur efisiensi penggunaan resource sebelum dan sesudah penerapan HPA.
3. Mengevaluasi performa sistem pada berbagai skenario beban dinamis.
4. Menentukan konfigurasi HPA yang memberikan keseimbangan optimal antara stabilitas dan efisiensi resource.

4.2. Manfaat

Manfaat penelitian ini adalah:

1. Memberikan pemahaman empiris mengenai efektivitas HPA dalam menjaga performa sistem.
2. Menjadi referensi bagi praktisi DevOps dalam melakukan konfigurasi autoscaling.
3. Memberikan kontribusi akademik dalam kajian performa sistem terdistribusi berbasis container.
4. Menjadi dasar penelitian lanjutan terkait optimasi autoscaling berbasis metrik tambahan.

5. METODOLOGI PENELITIAN

Metodologi yang digunakan adalah metode eksperimen kuantitatif dengan tahapan sebagai berikut:

1. Studi Literatur

   Mengkaji teori terkait:

   - Cloud-native architecture
   - Kubernetes orchestration
   - Mekanisme autoscaling (khususnya Horizontal Pod Autoscaler)
   - Konsep stabilitas sistem dan efisiensi resource
   - Penelitian terdahulu mengenai performa autoscaling

Tahap ini bertujuan untuk menentukan variabel penelitian, parameter HPA, serta Key Performance Indicator (KPI) yang digunakan dalam eksperimen.

2. Perancangan Lingkungan Uji

   Tahap ini meliputi:

   - Membangun cluster Kubernetes
   - Mendeploy aplikasi cloud-native (stateless service)
   - Mengaktifkan metrics-server
   - Mengonfigurasi HPA berbasis CPU utilization

   Parameter HPA yang digunakan:

   - Min Replica: 1
   - Max Replica: 5
   - Target CPU Utilization: 50%, 70%, dan 80% (variasi eksperimen)
   - Metrics: Resource (CPU)
   - Scaling behavior: default Kubernetes

   Variasi threshold CPU digunakan untuk menganalisis sensitivitas dan respons scaling terhadap perubahan beban.

3. Perancangan Skenario Pengujian

   Pengujian dilakukan dalam dua kondisi sistem:

   - Tanpa HPA (baseline)
   - Dengan HPA aktif

   Skenario beban yang digunakan:

   1. Skenario Beban Bertahap (Gradual Load)

      Beban meningkat secara bertahap (misalnya 20 → 50 → 100 request per second).

   2. Skenario Lonjakan Beban (Spike Load)

      Beban meningkat secara tiba-tiba (misalnya 50 → 200 request per second dalam waktu singkat).

   Pada tahap ini juga ditentukan acceptable parameter untuk setiap KPI sebagai dasar evaluasi efektivitas HPA.

4. Pengumpulan Data

   Pengumpulan data dilakukan menggunakan tools load testing dan monitoring untuk mencatat metrik berikut:

   KPI 1 – Stabilitas Sistem

   - p95 Latency

- Error Rate (%)
- Latency degradation saat spike

KPI 2 – Efisiensi Resource

- Average CPU Utilization (%)
- Idle Resource (%)
- Pod utilization ratio

KPI 3 – Scaling Behavior

- Scaling time (detik)
- Jumlah pod saat peak load
- Recovery time setelah spike

5. Analisis Data

   Analisis dilakukan dengan pendekatan komparatif antara baseline dan HPA aktif berdasarkan KPI yang telah ditentukan.

   Sistem dinyatakan stabil apabila:

   - p95 latency ≤ 400 ms
   - Error rate ≤ 2%
   - Tidak terjadi CPU overload (>90%) dalam durasi lama

   Sistem dinyatakan efisien apabila:

   - Average CPU utilization berada pada rentang 50–75%
   - Idle resource ≤ 40%
   - Tidak terjadi overprovisioning ekstrem

   HPA dianggap lebih efektif dibanding baseline apabila:

   - Terjadi penurunan p95 latency minimal 30% saat peak load
   - Error rate lebih rendah secara signifikan
   - CPU tidak mencapai overload berkepanjangan
   - Scaling time ≤ 30 detik
   - Recovery time ≤ 60 detik

   Analisis juga mencakup evaluasi trade-off antara stabilitas dan efisiensi resource.

6. Penarikan Kesimpulan

   Kesimpulan ditarik berdasarkan hasil analisis kuantitatif terhadap seluruh KPI.

   Penelitian akan menentukan:

   - Apakah HPA secara signifikan meningkatkan stabilitas sistem dibanding baseline

- Apakah HPA meningkatkan efisiensi penggunaan resource
- Konfigurasi threshold CPU yang paling optimal berdasarkan hasil eksperimen

Hasil penelitian akan menghasilkan rekomendasi konfigurasi HPA yang sesuai untuk aplikasi cloud-native dengan karakteristik beban dinamis.

DAFTAR PUSTAKA

Augustyn, D. R., Wyciślik, Ł., & Sojka, M. (2024). Tuning a Kubernetes horizontal pod autoscaler for meeting performance and load demands in cloud deployments. *Applied Sciences, 14*(2), 646. doi:10.3390/app14020646

Dang-Quang, N.-M., & Yoo, M. (2021). Deep learning–based autoscaling using bidirectional long short-term memory for Kubernetes. *Applied Sciences, 11*(9), 3835. doi:10.3390/app11093835

Dogani, J., Namvar, R., & Khunjush, F. (2023). Auto-scaling techniques in container-based cloud and edge/fog computing: Taxonomy and survey. *Computer Communications, 209*, 120–150. doi:10.1016/j.comcom.2023.06.010

Mondal, S. K., Wu, X., Kabir, H. M. D., Dai, H.-N., Ni, K., Yuan, H., & Wang, T. (2023). Toward optimal load prediction and customizable autoscaling scheme for Kubernetes. *Mathematics, 11*(12), 2675. doi:10.3390/math11122675

Nguyen, T.-T., Yeom, Y.-J., Kim, T., Park, D.-H., & Kim, S. (2020). Horizontal pod autoscaling in Kubernetes for elastic container orchestration. *Sensors, 20*(16), 4621. doi:10.3390/s20164621

Patel, A., & Sharma, R. (2019). Using horizontal pod autoscaler for performance optimization in multi-AZ Kubernetes clusters. *International Journal of Cloud Computing, 8*(4), 101–120.

Rabiu, S., Yong, C. H., & Mohamad, S. M. S. (2022). A cloud-based container microservices: A review on load-balancing and auto-scaling issues. *International Journal of Data Science, 3*(2), 80–92. doi:10.18517/ijods.3.2.80-92.2022